

Meilenstein 1 — Zeitraumsbericht (ENTWURF)

Zeitraum: Projektstart (Februar 2026) bis 31.08.2026. Dieser Bericht belegt, was in diesem Zeitraum getan wurde; künftige Berichte enthalten nur noch das Delta zum vorigen Stichtag (siehe [../README.md](#)).

Arbeitsstand, nicht veröffentlicht. Stichtag des Meilensteins ist der 31.08.2026; dieser Entwurf basiert auf dem Inventurstand vom 22.08.2026 (`main@99f61ee1` , 351 geschlossene Issues, 324 gemergte PRs — siehe [anker.md](#)). Vor der Abnahme wird das Delta bis zum Stichtag nachgezogen. Jede Aussage ist über die [Bausteine](#) auf Issue, PR und Code rückführbar.

Management Summary

OPAA ist in sechs Monaten von einer leeren Projektidee zu einem lauffähigen, öffentlich demonstrierbaren Wissensassistenten für die öffentliche Verwaltung gewachsen — mit belegten Antworten, echtem Rechtemodell, eigener Demo-Instanz und einer Arbeitsweise, in der Menschen und KI-Agenten gemeinsam über 320 Pull Requests geliefert haben.

Phase 1 der Produktvision („Souveräner Wissensassistent“) ist zu geschätzt rund 80 % umgesetzt.

Das Fundament — Wissensquellen, Bibliotheken, Rechtemodell, belegte Antworten, Audit-Grundstufe, Oberfläche, Deployment — steht vollständig und trägt das Hauptgewicht der Phase. Offen sind vor allem Retrieval-Qualität (hybride Suche, Reranking, Konfidenz), Streaming-Antworten, der echte Verzeichnisanschluss, DSGVO-Rechte und die Betriebsreife jenseits von Docker Compose (Details in Abschnitt 6).

Was heute konkret möglich ist:

- **Installieren und betreiben:** kompletter Stack per Docker Compose mit Schnellstart-Konfiguration, Betriebsmetriken und Gesundheitsendpunkt; eine öffentliche Testinstanz läuft.
- **Anmelden:** über den Verzeichnisdienst des Hauses (OIDC/Keycloak), Konten entstehen automatisch bei der Erstanmeldung.
- **Wissen anbinden:** Wissensbibliotheken per Vorlage anlegen — aus Dateiverzeichnissen, Webverzeichnissen und RSS-Feeds (inkl. Behörden-Websites auf GSB-Basis) oder per Upload mit Drag-and-drop; mit Verbindungstest, Zeitplan und Dokumentenverwaltung in der Oberfläche.
- **Rechtekonform suchen und fragen:** Chat mit Gesprächsverlauf in Spaces; jede Antwort mit geprüften Belegen, Sprung ins Originaldokument und einstellbarem Suchbereich — wer etwas nicht lesen darf, bekommt es auch über die Suche nicht zu sehen.
- **Wissen teilen und steuern:** Spaces, Bibliotheks-Freigaben an Personen und Gruppen, vollständig über die Oberfläche verwaltbar; jede Rechteänderung historisiert und im Audit-Protokoll nachweisbar.
- **Moderne, barrierefreie Oberfläche:** eigenes Designsystem mit konfigurierbarem Branding, Dunkelmodus und automatisiert geprüfter Barrierefreiheit (BITV/WCAG) — durchgängig deutsch.

- **Vorführen:** Demo-Installation „Stadt Rheinfurt“ mit umfangreichem fiktivem Verwaltungskorpus, mehreren Nutzerkonten und Drehbuch für verschiedene Szenarien.

Dieser Bericht stellt die erbrachten Leistungen im Einzelnen zusammen und benennt die Lücken ebenso deutlich wie das Erreichte.

1 · Projektsetup und Arbeitsweise

Das Projekt hat nicht nur Software geliefert, sondern eine funktionierende Organisationsform:

- **Mensch-KI-Kollaborationsmodell** von Anfang an (PR#1): dokumentierte Agenten-Rollen — Product Manager, Developer, Code Reviewer, QA-Engineer, Marketing, UX sowie sechs Stakeholder-Perspektiven der Verwaltung für Konzept-Reviews (#172–#184, #218, #459).
- **Verbindliche Arbeitsregeln** (AGENTS.md): Branch-/Issue-Disziplin, Conventional Commits, Reproduktionsnachweis bei Bugfixes, Epic-Führung über native Sub-Issues (#295, #335, #346, #566).
- **Projektsprache Deutsch** für Issues, PRs, Doku und alle nutzerseitigen Texte (#186, #219, #221).
- **Rechtlicher Rahmen:** AGPL-3.0 mit CLA-Prozess samt automatisierter Signaturprüfung (PR#104, PR#105).
- **Täglicher Projektreport** als generierte GitHub-Pages-Seite mit Management Summary und Epic-Zuordnung (#248, #285, #321, #373) — Projektsteuerung als Nebenprodukt der CI.
- **CI/CD:** GitHub-Actions-Pipeline mit Backend-/Frontend-Builds, Lint, Tests, E2E, Docker-Images nach GHCR, Branch-Schutz, Auto-Merge und Build-Cache-Optimierung (#23, #102, #196, #625, #644).

2 · Technische Grundlagen

- **Stack steht und ist aktuell:** Java 21 / Spring Boot 4.1 / Spring AI 2.0, React 19 / TypeScript 6 / MUI 9 / Vite 8, PostgreSQL 18 mit pgvector, Liquibase (#6, #7, #9, #188, #189).
- **API-First:** Alle DTOs werden aus der OpenAPI-Spezifikation generiert — Backend und Frontend aus derselben Quelle (#8, #133, #152, ADR-0006).
- **Entscheidungskultur:** 18 gepflegte ADRs; überholte werden entfernt oder aktualisiert statt stehen gelassen (#326, #324).
- **Testfundament:** Unit-, Integrations- und Migrationstests, E2E-Suite mit Playwright gegen den echten Compose-Stack (#231–#233), Testcontainer-Infrastruktur mit Template-DB und Kontext-Konsolidierung, die die Suite massiv beschleunigt hat (#497, PR#499, PR#648, PR#698).
- **Suchqualität ist messbar:** eigene Eval-Korpora (Comichelden, 200 europäische Großstädte), Golden Datasets, Metrik-Harness (Hit Rate, MRR, nDCG, Recall) und ein CI-Regressionsjob mit Baseline, der Verschlechterungen automatisch als Issue meldet (#224–#228, #234, #306, #721).

3 · Produktvision und Konzeption

- **Klare Positionierung:** souveräne, quelloffene KI-Plattform für die öffentliche Verwaltung, mit den Leitprinzipien Belegbarkeit und Verteilbarkeit (ADR-0014, Epic #338 mit #339–#343).
- **Elf Themenbereiche als Spezifikationsgerüst** (A–K), je mit eigener Feature-Spezifikation (#340, #360–#363); Use Cases, Konzeptglossar und bewusste Abgrenzungen („Bewusst nicht“).
- **Konzeptionelle Grundsatzentscheidungen** wurden aktiv getroffen statt vertagt: Zielbild der Chat-Kanäle (#352), lokal-first als Modell-Voreinstellung (#353), Zuschnitt des Zitierzwangs (#354/#386), Umfang des Audit-Protokolls (#355), Storage-Zielbild (#351), Mandantengrenze (#356); dazu eine dokumentierte GraphRAG-Recherche als Entscheidungsgrundlage für den Wissensgraphen (#317).
- **Roadmap mit datiertem Meilenstein** und Arbeitsteilung (#461).

4 · Implementierte Features (gegen Phase 1 der Vision)

Wissensschicht & Retrieval (A)

Vektorsuche mit pgvector, Antwortgenerierung mit Quellenangaben, überlappendes Chunking (#374), deterministische **Belegvalidierung:** jeder Beleg wird gegen die tatsächlich abgerufenen Fundstellen geprüft und ungültige Belege sichtbar gekennzeichnet (#386). Belege führen bis zum Original: Download-Endpunkt und Deeplink aus dem Beleg in die Wissensbibliothek (#736, #738), bei Feed-Anlagen samt Herkunfts-Link auf den Feed-Eintrag (#493). Suchbereichssteuerung per @-Bibliotheksreferenzen im Chat (#526, #560). Offen für Phase 1: hybride Suche und Reranking.

Wissensquellen & Indizierung (B)

Drei Aufnahmewege — Verzeichnis, Webverzeichnis/URL-Crawling, Upload — plus **RSS-Feeds als erster Konnektor-Quellentyp** samt Anlagenübernahme und Government-Site-Builder-Profil (#463–#468). **Bibliothekstypen mit gespeicherter Quellkonfiguration** (ADR-0018, Epic #486): Anlage per Template, Verbindungstest, Zeitplan je Bibliothek, sichere Zugangsdatenverwahrung, Pfad-Allowlist. Formaterkennung anhand des Inhalts statt der Endung (#404), Prüfsummen-Skip, asynchrone Verarbeitung, **Speicherkontingent je Bibliothek** (#119). **Dokumentenverwaltung in der Oberfläche:** Dokumentliste mit Paging und Stichwortsuche, Upload per Drag-and-drop, Löschen, Statusanzeige, übersprungene Dokumente mit Grund (#422, #513, #517). Die Quellenzugriffe sind gegen SSRF, Redirect-Tricks und Zugangsdaten-Exfiltration gehärtet (#267, #538, #617, #651, #693).

Spaces, Bibliotheken & Rechte (C/F)

Spaces mit Mitgliedschaften und Rollen, persönlicher Space je Nutzer, und **Wissensbibliotheken als eigenständige Rechteobjekte** mit Grants an Personen und Gruppen (#199–#202). Die Rechteprüfung sitzt in der Vektorsuche selbst. **Space↔Wissensbibliothek-Zuordnung als Kuratierung:** Nutzer assoziieren die Bibliotheken, auf die sie berechtigt sind, mit ihren Spaces — wirksam in API und Retrieval (#203, #686). Gruppen aus dem Verzeichnisabgleich als Rechtesubjekt (#200, #237), **lückenlose Historisierung von Rechten und Mitgliedschaften** mit Stichtags-Rekonstruktion (#238),

Organisationsgrenze auf Datenbankebene mit strukturellem Prüflauf (#289, #390, #400, #401).

Rechteverwaltung vollständig über die Oberfläche: Freigaben an Personen und Gruppen erteilen, Rollen ändern und entziehen, dazu Space- und Gruppenverwaltung (#421, #423).

Identität & Anmeldung (F)

OIDC/Keycloak-Anbindung mit automatischer Nutzerprovisionierung (#108–#110), daneben ein abgetrennter dev-Modus für die Entwicklung, per Startguard erzwungen. Robustheit gegen parallele Erstanmeldungen (#293, #307), Silent-Token-Renew statt Sofort-Logout (#737).

Chat & Oberfläche (I)

Persistente Chats in Spaces mit serverseitigem Verlauf, LLM-generierten Titeln und Chatliste (Epic #523, #557); umfangreiche Race-Condition-Härtung der Frontend-Stores. **Komplettes UI-Redesign** auf eigenem Designsystem: Design-Tokens, Theme, konfigurierbares Branding, App-Shell, Assistenten für Space- und Bibliotheksanlage, Fußnoten-Fundstellen mit Belegfenster, Dunkelmodus (#580–#597, #654, #658). Barrierefreiheit als Richtlinie (BITV/WCAG) mit automatisierten Prüfungen in Lint und E2E (#584–#586).

Modelle & zentrale Steuerung (E)

Austauschbare, **OpenAI-kompatible Modellanbieter**, für Chat und Einbettung getrennt konfigurierbar — lokal betriebene Modelle (vLLM, Ollama) sind die Voreinstellung, eine unkonfigurierte Installation redet nicht nach außen (#47, #353). Modellverwaltung als verwaltbare Objekte und zentrale Vorgaben je Space/Bibliothek bleiben Phase-1-Arbeit.

Sicherheit & Nachweis (G)

Ratenbegrenzung, CORS-Härtung, Sicherheits-Header, Härtungsdokumentation (#61, #62, #409, #250). Die **erste Stufe des revisionssicheren Audit-Trails ist geliefert** (#355, #391–#395): nur-anfügende Ablage mit entzogenen Änderungsrechten, Erfassung aller Rechte- und Verwaltungsereignisse, Revisionszugriff ohne personenbezogene Auswertung, Selbstprotokollierung jedes Protokollzugriffs, Aufbewahrung mit automatischer Löschung. Benannte Grenze: keine Prüfsummenverkettung — Manipulation mit direktem Datenbankzugang liegt beim Betreiber.

Betrieb & Demo (J/H)

Betriebsmetriken und Gesundheitsendpunkt für die Überwachung (#65). Docker Compose für den Gesamtstack inkl. Keycloak, .env-Schnellstart (#16, #157, #716), öffentliche Testinstanz, und die **Demo-Instanz „Stadt Rheinfurt“**: generierter Verwaltungskorpus einer fiktiven Stadt, Seed-Profile für Demo und E2E, Installationsanleitung und Vorführ-Drehbuch (Epic #708, #709–#713).

5 · Ehrlicher Befund: Lücken und bewusste Schnitte

Nichts davon ist verschwiegen — alles ist als Entscheidung oder offenes Issue dokumentiert:

- **Hybride Suche und Reranking fehlen** — reine Vektorsuche ist für attributreiche Fachdaten eine bekannte Schwäche (Phase-1-Ziel, offen).
- **Zitierzwang wurde bewusst verkleinert:** statt Verweigerungsmodus und Space-Schalter gibt es die deterministische Belegvalidierung — eine dokumentierte Maintainer-Entscheidung, kein stilles Scheitern (#354, #387–#389 „not planned“).
- **Agenten, Prompts & Werkzeuge (D) und Verwaltungs-Spezifika (K, z. B. Leichte Sprache)** sind noch nicht begonnen — Phase-2- bzw. spätere Phase-1-Arbeit.
- **DSGVO-Vollständigkeit** (Löschrecht, Export), Schadsoftwareprüfung des Uploads und Streaming-Antworten stehen aus.

Der Report nennt durchgängig nur den Endzustand. Zwischenstände, die gebaut und wieder zurückgebaut wurden, sind keine Leistungsposten; sie bleiben ausschließlich in den [Bausteinen](#) dokumentiert.

6 · Offen für Phase 1 — priorisierte Restliste

Was zur Phase-1-Definition der Vision („Souveräner Wissensassistent“) noch fehlt, nach Gewicht:

Kern des Wissensassistenten

1. **Hybride Suche mit Reranking** — wichtigste Retrieval-Lücke für Fachdaten
2. **Ausgabe im Fluss (Streaming)** — größter Einzelfaktor der gefühlten Antwortzeit
3. **Konfidenz als erklärte Größe** und **erklärbares Chunking**
4. **Textwerkzeuge einschließlich Leichter Sprache** — Bereich K, bisher ohne einen einzigen Vorgang

Identität & Modelle 5. **Echter Verzeichnisanschluss** — hinter dem Abgleich steht bislang nur ein No-Op-Client; LDAP-/SCIM-Client und Kontenlebenszyklus fehlen 6. **Modellverwaltung und zentrale Vorgaben als Obergrenze** je Space/Bibliothek 7. Sitzungsverwaltung mit erzwungener Neuansmeldung, Einschränkung auf Netzbereiche

Nachweis & Compliance 8. **DSGVO-Vollständigkeit** — Löschrecht und Datenexport (#143) 9. **Schadsoftwareprüfung des Uploads** — Voraussetzung für den Produktivbetrieb 10. Software-Stückliste, signierte Builds, Sicherheits-Scans in der CI, unabhängige Prüfung 11. Audit-Governance-Reste: Fristwarnung (abhängig von #216), Auswertungs-Governance (#239)

Betrieb & Oberfläche 12. **Kubernetes mit Hochverfügbarkeit** und die **air-gapped-Lieferung** (Abbilder, Modellgewichte, Stückliste als übertragbares Paket) 13. Antwort-Bewertung mit Speicherung, API-Token-Verwaltung, vollständige Mehrsprachigkeit (#145)

7 · Zahlen zum Inventurstand

Gemergte Pull Requests	324
Geschlossene Issues	351 (davon ~10 % bewusst „not planned“)

Architecture Decision Records	18 gepflegt
Datenbank-Migrationen	fortlaufend über Liquibase, mit strukturellem Schema-Prüflauf
Themenbereiche mit Lieferung	10 von 12 Inventur-Bereichen (offen: D, K)

Erstellt aus der Leistungsinventur (Issue #744, Vorgehen siehe [../README.md](#)). Fortschreibung zum Stichtag: Delta ab `99f61ee1` bzw. Issues geschlossen nach 2026-08-22, siehe [anker.md](#).
